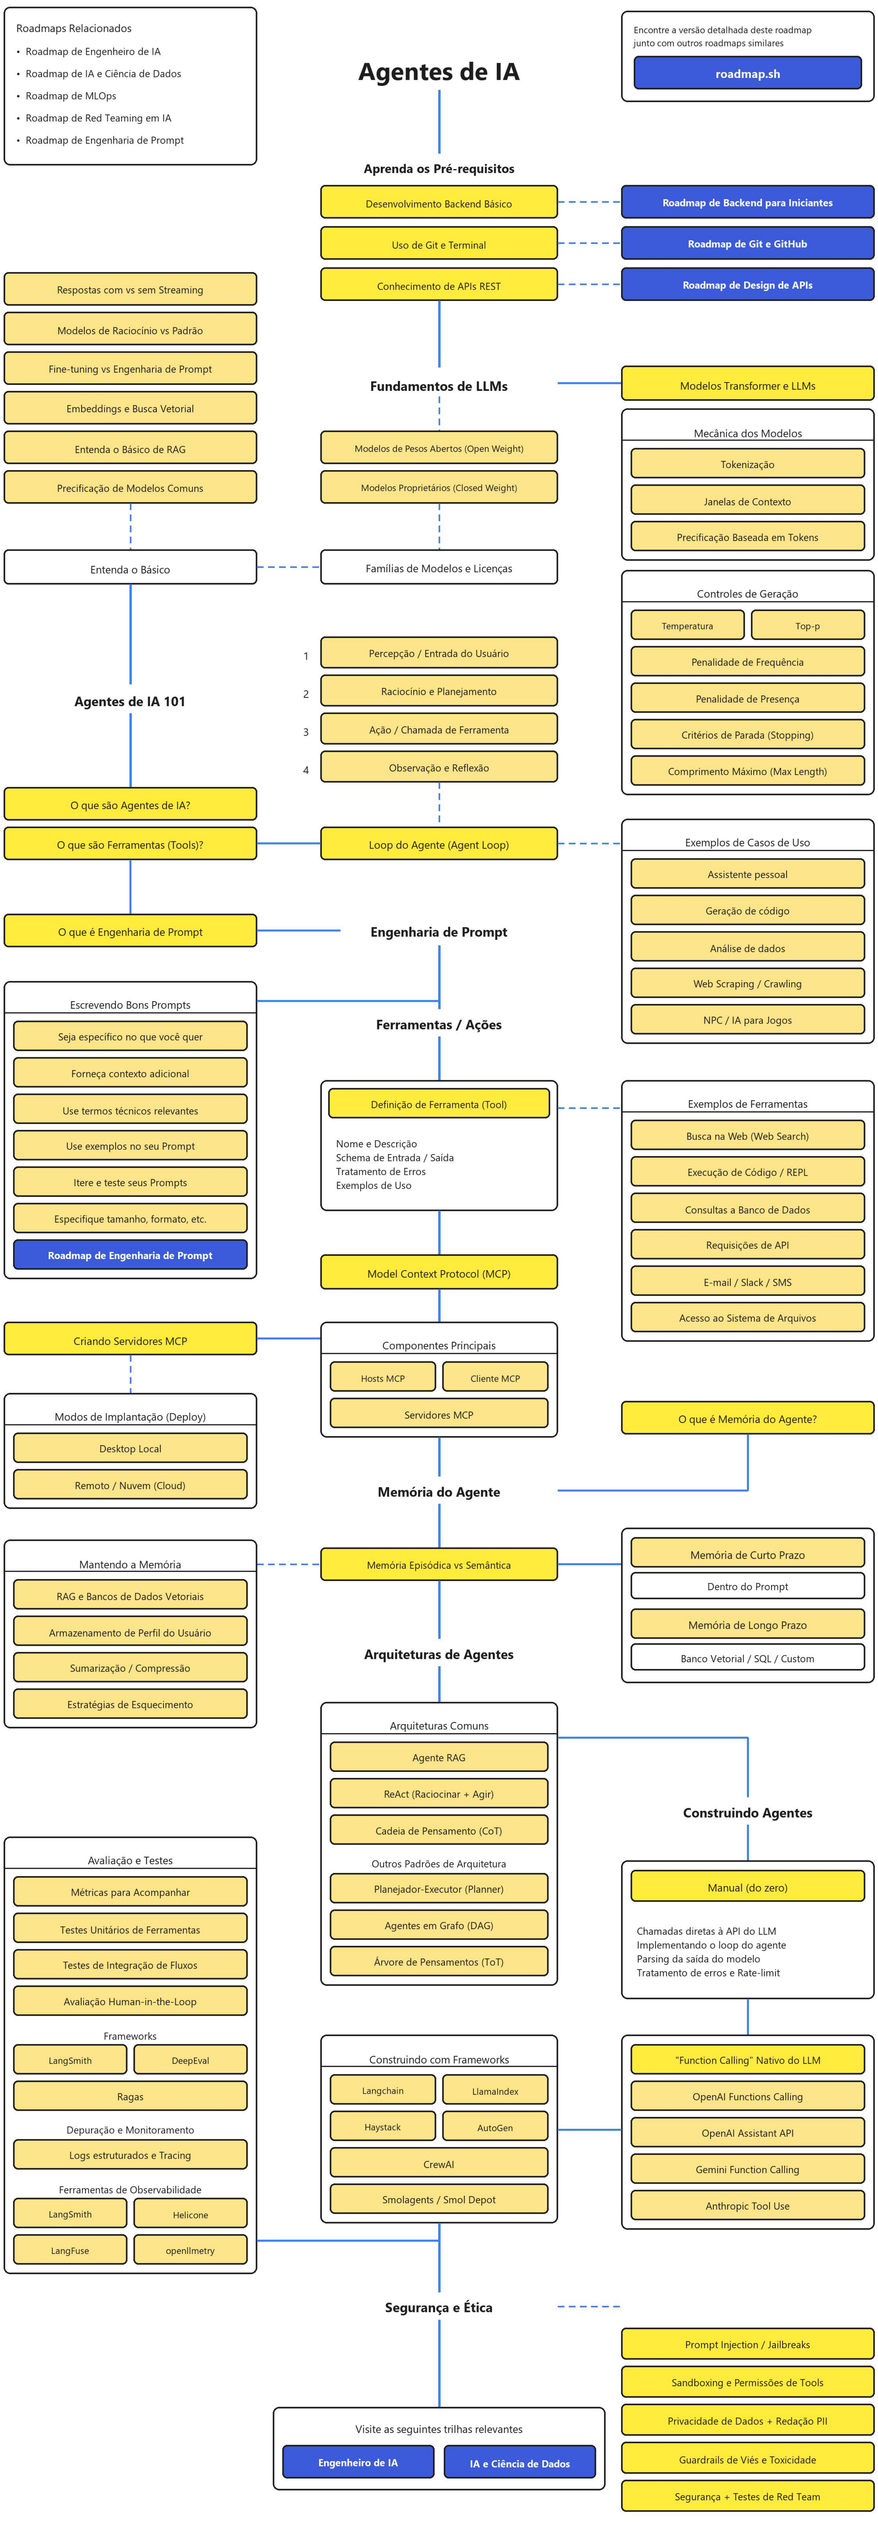

Roadmaps Relacionados
Roadmap de Engenheiro de IA
Roadmap de IA e Ciência de Dados
Roadmap de MLOps
Roadmap de Red Teaming em IA
Roadmap de Engenharia de Prompt
Agentes de IA
Encontre a versão detalhada deste roadmap junto com outros roadmaps similares
roadmap.sh
Aprenda os Pré-requisitos
Desenvolvimento Backend Básico
Roadmap de Backend para Iniciantes
Uso de Git e Terminal
Roadmap de Git e GitHub
Conhecimento de APIs REST
Roadmap de Design de APIs
Respostas com vs sem Streaming
Modelos de Raciocínio vs Padrão
Fine-tuning vs Engenharia de Prompt
Embeddings e Busca Vetorial
Entenda o Básico de RAG
Precificação de Modelos Comuns
Fundamentos de LLMs
Modelos Transformer e LLMs
Modelos de Pesos Abertos (Open Weight)
Modelos Proprietários (Closed Weight)
Mecânica dos Modelos
Tokenização
Janelas de Contexto
Precificação Baseada em Tokens
Entenda o Básico
Famílias de Modelos e Licenças
Controles de Geração
Temperatura
Top-p
Penalidade de Frequência
Penalidade de Presença
Critérios de Parada (Stopping)
Comprimento Máximo (Max Length)
1 Percepção / Entrada do Usuário
2 Raciocínio e Planejamento
3 Ação / Chamada de Ferramenta
4 Observação e Reflexão
Agentes de IA 101
O que são Agentes de IA?
O que são Ferramentas (Tools)?
Loop do Agente (Agent Loop)
Exemplos de Casos de Uso
Assistente pessoal
Geração de código
Análise de dados
Web Scraping / Crawling
NPC / IA para Jogos
O que é Engenharia de Prompt
Engenharia de Prompt
Escrevendo Bons Prompts
Seja específico no que você quer
Forneça contexto adicional
Use termos técnicos relevantes
Use exemplos no seu Prompt
Itere e teste seus Prompts
Especifique tamanho, formato, etc.
Roadmap de Engenharia de Prompt
Ferramentas / Ações
Definição de Ferramenta (Tool)
Nome e Descrição
Schema de Entrada / Saída
Tratamento de Erros
Exemplos de Uso
Exemplos de Ferramentas
Busca na Web (Web Search)
Execução de Código / REPL
Consultas a Banco de Dados
Requisições de API
E-mail / Slack / SMS
Acesso ao Sistema de Arquivos
Model Context Protocol (MCP)
Criando Servidores MCP
Componentes Principais
Hosts MCP
Cliente MCP
Servidores MCP
Modos de Implantação (Deploy)
Desktop Local
Remoto / Nuvem (Cloud)
O que é Memória do Agente?
Memória do Agente
Mantendo a Memória
RAG e Bancos de Dados Vetoriais
Armazenamento de Perfil do Usuário
Sumarização / Compressão
Estratégias de Esquecimento
Memória Episódica vs Semântica
Memória de Curto Prazo
Dentro do Prompt
Memória de Longo Prazo
Banco Vetorial / SQL / Custom
Arquiteturas de Agentes
Arquiteturas Comuns
Agente RAG
ReAct (Raciocinar + Agir)
Cadeia de Pensamento (CoT)
Outros Padrões de Arquitetura
Planejador-Executor (Planner)
Agentes em Grafo (DAG)
Árvore de Pensamentos (ToT)
Construindo Agentes
Avaliação e Testes
Métricas para Acompanhar
Testes Unitários de Ferramentas
Testes de Integração de Fluxos
Avaliação Human-in-the-Loop
Frameworks
LangSmith
DeepEval
Ragas
Depuração e Monitoramento
Logs estruturados e Tracing
Ferramentas de Observabilidade
LangSmith
Helicone
LangFuse
openllmetry
Manual (do zero)
Chamadas diretas à API do LLM
Implementando o loop do agente
Parsing da saída do modelo
Tratamento de erros e Rate-limit
Construindo com Frameworks
Langchain
LlamaIndex
Haystack
AutoGen
CrewAI
Smolagents / Smol Depot
"Function Calling" Nativo do LLM
OpenAI Functions Calling
OpenAI Assistant API
Gemini Function Calling
Anthropic Tool Use
Segurança e Ética
Prompt Injection / Jailbreaks
Sandboxing e Permissões de Tools
Privacidade de Dados + Redação PII
Guardrails de Viés e Toxicidade
Segurança + Testes de Red Team
Visite as seguintes trilhas relevantes
Engenheiro de IA
IA e Ciência de Dados